

PROPOSTA 1.

INTELIGÊNCIA COMPUTACIONAL E OTIMIZAÇÃO

Elaborado por:

António Nanita, 122240

Miguel Valadares, 98345

Gonçalo Botelho, 98893

Rodrigo Alves, 121700

Índice

Introdução	3
Aplicações Reais	3
Contextualização Teórica	3
Métodos de Busca em Linha	3
Método de Descida Máxima	4
Método de <i>Newton-Raphson</i>	4
Condições de <i>Wolfe</i>	4
Lista de Funções	5
Função de <i>Rosenbrock</i>	5
Função Matemática Complexa $f(x,y)$	6
Função Matemática Complexa $g(x,y)$	7
Metodologia	8
Bibliografia	9

Introdução

A otimização de funções não lineares é um campo fundamental na matemática aplicada e na ciência da computação, desempenhando um papel crucial na resolução de uma variedade de problemas complexos. O problema em questão reside na minimização de funções não lineares, um desafio que permeia diversas áreas do conhecimento, desde a modelagem de fenômenos físicos até à otimização de parâmetros em aplicações de *machine learning*.

As funções não lineares podem representar uma ampla diversidade de fenômenos e processos da vida real, muitas vezes caracterizados por comportamentos não triviais e múltiplos mínimos locais. A busca pelo mínimo global neste tipo de funções é frequentemente complicada pela presença desses mínimos locais, tornando o problema de otimização não linear altamente desafiador.

A complexidade destas funções e a presença de múltiplos mínimos locais exigem métodos de otimização eficazes que possam encontrar soluções de forma rápida e precisa. Nesse contexto, os métodos de busca em linha emergem como ferramentas poderosas, explorando eficientemente o espaço de busca para encontrar os mínimos desejados.

Aplicações Reais

Uma aplicação da otimização de funções não lineares, e que já trabalhamos, consiste no desenvolvimento e treino de redes neurais artificiais, mais especificamente no *backpropagation*. Em outras palavras, permite que a rede neuronal “aprenda” consoante um erro obtido, e o objetivo consiste em encontrar o menor erro possível.

Contextualização Teórica

Métodos de Busca em Linha

Os métodos de busca em linha são algoritmos que visam responder ao problema anteriormente identificado. Através de várias iterações, procura-se atingir soluções aproximadas x^* em problemas de minimização ($\min_x f(x) = ?$).

A partir de um ponto inicial /semente, pretende-se, em cada passo, avançar numa direção de descida, de forma a garantir que o valor seguinte é sempre inferior ao anterior, com o objetivo de atingir o mínimo. Neste trabalho abordar-se-ão alguns métodos de busca

diferentes, como o Método de Descida Máxima e o Método de *Newton-Raphson*. Para além disso, será analisada a utilização das condições de *Wolfe*.

Método de Descida Máxima

O Método de Descida Máxima, também conhecido como método do gradiente descendente, é uma abordagem iterativa usada para encontrar o mínimo de uma função. Este método baseia-se na minimização iterativa de uma função, ajustando os parâmetros na direção oposta ao gradiente local.

O gradiente indica a direção de maior inclinação da função, e ao mover-se na direção oposta, procura-se atingir o ponto de mínimo da função. A atualização dos parâmetros ocorre multiplicando o gradiente pela taxa de aprendizagem, controlando assim o tamanho dos passos em cada iteração. Este método revela-se particularmente eficaz em problemas de otimização convexa, proporcionando uma abordagem sistemática para a convergência em direção ao mínimo global.

Método de *Newton-Raphson*

O Método de *Newton-Raphson* é uma técnica iterativa utilizada para encontrar raízes de funções ou extremos (mínimos/máximos). Esta abordagem fundamenta-se na aproximação local da função por uma parábola, utilizando informações da função e da sua segunda derivada (curvatura). Ao determinar o mínimo ou máximo desta parábola, obtém-se uma estimativa mais precisa da solução.

A atualização dos parâmetros leva em consideração tanto o gradiente como a matriz Hessiana da função. Este método permite uma convergência mais rápida em comparação com o Método de Descida Máxima, uma vez que incorpora informações adicionais sobre a curvatura da função. Contudo, o cálculo da matriz Hessiana pode ser computacionalmente exigente, e em alguns casos, a singularidade ou complexidade do problema pode afetar a eficácia do método.

Condições de *Wolfe*

As condições de *Wolfe* são um conjunto de regras utilizadas na determinação do tamanho do passo ideal durante a otimização, sendo compostas por duas partes: a condição de diminuição suficiente e a condição de curvatura.

A condição de diminuição suficiente, também conhecida como condição de Armijo, garante que o passo dado resulta numa diminuição adequada do valor da função objetivo. A condição de curvatura garante que o tamanho do passo não seja excessivamente grande. Se este for muito grande, pode-se ultrapassar o mínimo pretendido. Estas condições ajudam a garantir a convergência dos algoritmos, sendo amplamente utilizadas.

Lista de Funções

Neste trabalho, iremos aprofundar a exploração dos métodos de busca em linha mencionados, aplicando-os a diversas funções. Além disso, realizaremos uma análise comparativa de desempenho entre esses métodos, considerando tanto os casos em que são aplicadas as condições de *Wolfe* quanto aqueles em que essas condições são desconsideradas.

Ao aplicar os métodos de busca em linha a diferentes funções, procuramos compreender como cada algoritmo se comporta perante diferentes tipologias de função. Desta forma, permitirá avaliar a robustez e a eficácia dos métodos em contextos variados, fornecendo *insights* valiosos sobre as suas características de desempenho em diferentes cenários.

A inclusão da análise com e sem as condições de *Wolfe* amplia a abordagem da avaliação, uma vez que as condições de *Wolfe* são critérios que garantem a convergência dos métodos de otimização.

Função de *Rosenbrock*

A função a ser estudada é uma variação da função de *Rosenbrock*, que é frequentemente utilizada como um desafio significativo para avaliar algoritmos de otimização devido às suas características distintas. A tipologia da função assemelha-se a um “vale alongado e estreito”, o que cria um ambiente desafiador para os métodos de otimização.

O mínimo global desta função ocorre em $x = 1$ e $y = 1$, onde o valor da função atinge o mínimo de zero. Contudo, para descobrir este mínimo é uma tarefa complexa devido à forma peculiar da função, que exige métodos de otimização robustos e eficientes.

A sensibilidade às condições iniciais é uma característica proeminente desta função, pois variações mínimas nas condições iniciais podem resultar em trajetórias de otimização distintas, evidenciando a influência crucial das mesmas no processo de busca pela solução ótima.

Além disso, a função de *Rosenbrock* modificada destaca a importância de estabelecer critérios de paragem adequados ao implementar algoritmos de otimização. Dada a sua complexidade, é essencial definir critérios que evitem convergência prematura ou que garantam uma exploração completa da superfície de otimização.

$$r(x, y) = 100(y - x^2)^2 + (1 - x)^2$$




Figura 1 - Função de Rosenbrock

Função Matemática Complexa $f(x,y)$

A função apresenta uma estrutura matemática complexa e desafiante, tornando-se um campo fascinante para o estudo de algoritmos de otimização. Composta por termos polinomiais, funções trigonométricas e a inclusão de parâmetros fixos como 100, 61, 25 e 16, esta função revela uma superfície de otimização com múltiplos termos não-lineares e não-convexa.

A introdução de termos trigonométricos, como $\cos(5y)$, adiciona uma dimensão cíclica à problemática, exigindo métodos robustos para lidar com oscilações. Os coeficientes diferenciados associados a cada termo refletem-se na convergência dos algoritmos, evidenciando a importância de ajustes precisos.

$$f(x, y) = (x^2 - 100)(x^2 - 61) + (y^2 - 25)(y^2 - 16) - 15 \cos\left(x - \frac{7}{5}\right) \cos\left(y - \frac{9}{z}\right)$$




Figura 2 - Função Matemática Complexa $f(x,y)$

Função Matemática Complexa $g(x,y)$

A função apresenta uma configuração matemática desafiante que incorpora termos polinomiais, constituindo um estímulo interessante para análise e otimização. Composta por fatores quadráticos $(x + 3)(x - 3)(x - 5)$ e a presença da variável linear y , esta função revela uma superfície de otimização com características não-lineares.

Os fatores quadráticos indicam raízes nos pontos $x = -3$, $x = 3$ e $x = 5$, sugerindo possíveis pontos críticos. A inclusão da variável y nos termos lineares adiciona uma dimensão ao problema, aumentando a complexidade da otimização.

A análise atenta da tipologia desta função, tendo em conta as raízes dos fatores quadráticos e a influência da variável y , é crucial para compreender a busca pelo mínimo global. A implementação de métodos de otimização eficazes torna-se essencial para explorar de forma eficiente esta complexa superfície de otimização.

$$g(x, y) = x(x + 3)(x - 3)(x - 5) + y(y + 3)(y - 3)(y - 5)$$




Figura 3 - Função Matemática Complexa $g(x,y)$

Metodologia

Tendo em conta os objetivos do trabalho, podemos fazer uma exploração de cada método, consoante cada função de teste, utilizados diferentes abordagens.

Diferentes Tolerâncias de Erro:

- Para cada função de teste, ajustaremos a tolerância de erro do método de busca em linha para avaliar como isso afeta a convergência e a precisão da solução.
- Exploraremos uma gama de tolerâncias de erro para identificar o impacto na quantidade de iterações necessárias para alcançar a convergência.

Diferentes Números de Iterações:

- Realizaremos experimentos com diferentes números de iterações para observar como a convergência dos métodos de busca em linha é influenciada pela quantidade de iterações permitidas.
- Analisaremos a relação entre o número de iterações e a precisão da solução, bem como o tempo computacional necessário para atingir a convergência.

Diferentes Pontos Iniciais:

- Exploraremos o efeito dos pontos iniciais na convergência e na qualidade da solução obtida pelos métodos de busca em linha.
- Investigaremos como diferentes pontos iniciais podem influenciar a “trajetória da busca” e se podem levar a minimizantes locais ou globais distintos.

Após a realização das experiências, apresentaremos os resultados obtidos para cada função de teste, incluindo os mínimos e minimizantes locais ou globais encontrados, os vetores gradientes correspondentes e os parâmetros utilizados em cada caso.

Por fim, iremos analisar e interpretar os resultados obtidos, destacando padrões observados, tendências identificadas e insights relevantes sobre o desempenho e comportamento dos métodos de busca em linha em diferentes cenários de otimização.

Bibliografia

Bertolazzi, E. (2011). Unconstrained minimization. Lectures for PHD course on Numerical optimization

Humpherys, J., & Jarvis, T. J. (Eds.). (2011). Labs for Foundations of Applied Mathematics - Algorithm Design and Optimization (Vol. 2) Lectures for PHD course on Numerical optimization

Parkinson, A. R., Balling, R. J., & Hedengren, J. D. (2013). Optimization Methods for Engineering Design - Applications and Theory. Brigham Young University.

Bazzet, D. T. (14 de fevereiro de 2023). Intro to Gradient Descent || Optimizing High-Dimensional Equations. Obtido de Youtube:
<https://www.youtube.com/watch?v=fXQXE96r4AY>

Bierlaire, M. (04 de maio de 2019). 11 Descent methods - Playlist. Obtido de Youtube:
<https://www.youtube.com/playlist?list=PL10NOnsbP5Q7wNrYItE2GhKq05cVov97e>

Visually, E. (08 de outubro de 2021). Gradient Descent in 3 minutes. Obtido de Youtube:
<https://www.youtube.com/watch?v=qg4PchTECck>